

Modelado Estadístico del Dengue en Ecuador: Regresión Lineal y Clasificación Logística a partir del Registro Nacional del Ministerio de Salud Pública (2021–2025)

Noelia Bustan Alison Tapia Christopher Pineda Elian Jimenez Yimmy Angulo

Carrera de Computación Universidad Nacional de Loja

Contexto del Problema

El dengue, transmitido por *Aedes aegypti*, es uno de los principales problemas de salud pública del Ecuador, particularmente en zonas tropicales y subtropicales de la Costa y la Amazonía, con comportamiento estacional (**Semana Epidemiológica, SE**) e interanual (**Año**), asociado a factores climáticos, sanitarios y sociales.

Dos enfoques complementarios sobre el mismo dataset regional:

Predictivo (lineal simple y múltiple): explicar la **Edad** a partir de SE y Año.
Clasificación probabilística: dicotomizar la Edad en *Edad_Mayor* y aplicar **Regresión Logística**.

Cobertura: **Ecuador a nivel nacional** (25 provincias); Guayas, Manabí y Napo concentran el mayor número de casos. El objetivo general es evaluar en qué medida variables puramente temporales explican y predicen el perfil etario de los pacientes con dengue.

Ingeniería de Características

Dataset: registro oficial del MSP “*Datos_Dengue_MSP_Ene2021_Ago2025*” [3], hoja DCSA_DG_2021_2025: registro individualizado de casos confirmados a nivel nacional con variables **administrativas** (institución, unidad operativa, zona, provincia, cantón, parroquia), **demográficas** (sexo, edad, tipo de edad, autoidentificación étnica) y **clínico-epidemiológicas** (SE de inicio de síntomas, antecedente de viaje, resultado de laboratorio, condición final, diagnóstico).

Limpieza: se seleccionaron **Edad, SE y Año**; se eliminaron nulos (dropna()).

23,043 observaciones válidas

Periodo 2021–2025 | Edad promedio = 21.95 años | rango 1–103 años

Variables del estudio:

Edad – respuesta continua (fase lineal).

SE – predictor, estacionalidad intra-anual.

Año – predictor, tendencia interanual.

Edad_Mayor – respuesta binaria derivada:

$$\text{Edad_Mayor} = \begin{cases} 1, & \text{Edad} > \overline{\text{Edad}} = 21.95 \\ 0, & \text{Edad} \leq \overline{\text{Edad}} \end{cases}$$

Se usaron predictores puramente temporales, sin variables categóricas (provincia, sexo, etc.), para aislar y evaluar de forma controlada el poder explicativo del componente estacional y de tendencia, antes de incorporar covariables adicionales en trabajos futuros.

Fundamento del Modelo Logístico

A diferencia de la regresión lineal, la logística no estima un valor continuo sino la **probabilidad** $P(Y = 1 \mid X)$ de un evento binario, garantizada en $[0, 1]$ mediante la función sigmoide:

$$P(Y=1 \mid X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

Como referencia comparativa, un modelo logístico *simulado* (caída de un servidor según temperatura de CPU) alcanza un Pseudo R^2 de McFadden de **0.468** – fuerte poder discriminante por diseño – frente al Pseudo $R^2 = 0.0063$ del modelo regional de dengue, lo que contextualiza la magnitud real del ajuste obtenido con datos epidemiológicos.

Fase Predictiva Lineal

Regresión Lineal Simple

$$\widehat{\text{Edad}} = \beta_0 + \beta_1 \cdot \text{Año}$$

Parám.	Coef.	Err. est.	t	Valor-p
Intercepto	−2426.26	—	—	—
Año	1.2099	0.0903	13.39	< 0.001

Table 1. Edad ~ Año (n = 23,043).

$r = 0.088$, $R^2 = 0.0077$: el Año explica solo **0.77%** de la variabilidad de la Edad. Pendiente positiva y significativa ($p < 0.001$), pero de baja relevancia práctica dado el gran tamaño muestral – un punto central en estadística inferencial: **significancia $\neq$ relevancia**.

Regresión Lineal Múltiple

$$\widehat{\text{Edad}} = \beta_0 + \beta_1 \cdot \text{SE} + \beta_2 \cdot \text{Año}$$

Parám.	Coef.	Err. est.	t	Valor-p
Intercepto	−2567.75	185.89	−13.81	< 0.001
SE	0.0368	0.009	4.16	< 0.001
Año	1.2794	0.092	13.93	< 0.001

Table 2. OLS Edad ~ SE + Año (n = 23,043).

$R^2 = 0.008$ (R^2 ajustado = 0.008), $F = 98.37$ ($p < 0.001$): manteniendo Año constante, cada SE adicional se asocia con +0.037 años en la edad esperada; manteniendo SE constante, cada año calendario se asocia con +1.28 años – coeficiente casi idéntico al modelo simple, lo que confirma la estabilidad del efecto. Modelo globalmente significativo, pero de capacidad explicativa marginal.




Figure 1. Edad observada vs. estimada por el modelo regional (SE + Año), $R^2 = 0.008$. La dispersión evidencia la alta variabilidad individual frente a un ajuste de ingeniería casi determinístico ($R^2 = 0.995$) obtenido en la tarea de referencia simulada.

Diagnóstico de Residuos

Multicolinealidad: correlación SE–Año $r = -0.18$ (débil); VIF ≈ 1.034 en ambos predictores ($\ll 5$) $\Rightarrow$ **sin multicolinealidad relevante**: cada predictor aporta información independiente (estacionalidad vs. tendencia interanual).




Figure 2. Correlación entre Edad, SE y Año.

Normalidad y autocorrelación: Durbin–Watson = 1.911 (sin autocorrelación relevante). Omnibus = 5905.79 y Jarque–Bera = 12,849.7 ($p < 0.001$) rechazan normalidad (asimetría = 1.49, curtosis = 5.11), explicado por la naturaleza acotada y no simétrica de la Edad (mínimo 1 año, concentración en población económicamente activa, valores extremos hasta 103 años). El efecto se atenúa parcialmente por el gran tamaño muestral (Teorema del Límite Central). El número de condición elevado (Cond. No. = 3.39×10^6) responde a la diferencia de escalas SE (1–53) vs. Año (2021–2025), no a colinealidad real.

Curva de Probabilidad Logística Regional

Con los coeficientes del modelo $\text{Edad_Mayor} \sim \text{SE} + \text{Año}$ (columna siguiente) se construye la curva sigmoide de probabilidad en función del Año, manteniendo SE en su valor medio:




Figure 3. Probabilidad de Edad_Mayor vs. Año (SE fijo en su media). El tramo sombreado marca el rango real de datos (2021–2025); la curva completa (incl. proyección) ilustra la forma sigmoide teórica del modelo.

La probabilidad se mantiene muy por debajo del umbral de decisión (0.50) dentro del rango observado, consistente con el bajo poder discriminante del modelo (Pseudo $R^2 = 0.0063$) y con el colapso del clasificador hacia la clase mayoritaria.

Fase de Clasificación Probabilística

Modelo Logit regional: $\text{Edad_Mayor} \sim \text{SE} + \text{Año}$

Variable	Coef. (β)	Valor-p	OR
SE	0.0049	8.58×10^{-6}	1.0049
Año	0.1579	2.08×10^{-41}	1.1710

Table 3. n = 23,043; Pseudo R^2 McFadden = 0.0063.

Cada año calendario adicional incrementa en $\approx 17\%$ las probabilidades de un caso con Edad superior al promedio (OR= 1.171); el efecto de SE es marginal (+0.49%/semana). Ambos significativos ($p < 0.001$), pero el **Pseudo R^2 es apenas 0.0063**.

Matriz de Confusión y Umbral de Decisión




Figure 4. Umbral = 0.50.

Con umbral 0.50 el modelo regional **colapsa en la clase mayoritaria** (TP = 0); con 0.20 se invierte por completo (predice siempre la clase positiva). El modelo *simulado*, en cambio, sí exhibe el **trade-off teórico esperado** al mover el umbral (FN: 17→9; FP: 15→35), porque parte de un poder discriminante real. Mover el umbral **no calibra nada** cuando el Pseudo R^2 es casi nulo.

Impacto en Políticas Regionales

El ajuste de umbral solo es útil cuando el modelo ya posee poder discriminante suficiente. En el modelo regional del dengue, las probabilidades estimadas están concentradas en un rango muy estrecho, sin una franja amplia sobre la cual el umbral pueda operar de forma gradual. Sería **metodológicamente inadecuado** basar decisiones de focalización etaria (p. ej., priorizar vigilancia de adultos mayores en ciertas semanas) únicamente en este modelo: el diagnóstico correcto no es un problema de calibración de umbral, sino de **insuficiencia de las variables predictoras** disponibles.

Conclusiones y Recomendaciones

SE y Año son **significativos** ($p < 0.001$) en ambos modelos, pero su poder explicativo es **marginal** ($R^2 \approx 0.8\%$; Pseudo $R^2 \approx 0.6\%$); significancia estadística $\neq$ relevancia epidemiológica.

Sin multicolinealidad relevante (VIF ≈ 1.03), sin autocorrelación (DW ≈ 1.91) pero sin normalidad de residuos. El ajuste de umbral **no sustituye** a un modelo con poder discriminante insuficiente.

Recomendación: incorporar variables categóricas y clínicas adicionales (sexo, provincia, cantón, etnia, antecedente de viaje, diagnóstico) e interacciones/términos no lineales, antes de usar el modelo para focalización etaria, reportando siempre Pseudo R^2 y evaluando distintos umbrales.

Referencias

- [1] Andy Field. *Discovering Statistics Using IBM SPSS Statistics*. Sage Publications, London, 5 edition, 2018.
- [2] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, Hoboken, NJ, 3 edition, 2013.
- [3] Ministerio de Salud Pública del Ecuador. Base de datos de casos de dengue confirmados, enero 2021 – agosto 2025. Dirección de Vigilancia Epidemiológica, MSP Ecuador, 2025.
- [4] Douglas C. Montgomery, Elizabeth A. Peck, and G. Geoffrey Vining. *Introduction to Linear Regression Analysis*. Wiley, Hoboken, NJ, 6 edition, 2021.